



Solution d'archivage et de consultation de médias audio-numériques orientée recherche

Version 0.2 – 5/02/2007

Guillaume Pellerin pellerin@parisson.com>
Olivier Guilyardi <olivier@samalyse.com>

Objet:

L'objectif de ce document est de définir les moyens et l'organisation nécessaires à l'archivage et à la consultation de contenus multimédias numérisés pour leur valorisation. La société Parisson a développé pour ce faire le logiciel libre Telemeta¹ qui permet d'exporter, de transcoder et de sauvegarder des fichiers des fichiers audio non-compressés depuis un client vers un serveur à travers un réseau intranet ou internet. L'objectif et de pouvoir proposer aux communautés de chercheurs un outil simple de stockage audio, d'inclusion et d'édition des métadonnées autour d'une plate-forme centralisée et sécurisée. Les partenaires initiaux de ce projet sont le Laboratoire d'Ethnomusicologie (Université Paris X Nanterre, CNRS UMR 7138) et le Laboratoire d'Acoustique Musicale (Université Pierre et Marie Curie, CNRS UMR 7604, Ministère de la Culture et de la Communication).

1. Les besoins des organismes de recherche

De nombreux organismes de recherche ont aujourd'hui besoin de mettre à disposition une quantité importante de contenus numérisés ou prochainement numérisés. Cette situation ne nourrit bien sûr de la quantité croissante des informations récoltées mais aussi des besoins de sauvegardes d'anciennes archives analogiques dont l'état peut s'avérer critique. En ce sens, la numérisation des archives et leur mise à disposition à des entités telles que les bibliothèques nationales est un enjeu majeur pour la sauvegarde du patrimoine audiovisuel.

En outre, les réseaux numériques permettent aujourd'hui de mettre à disposition des contenus à distances avec des accès personnalisés. Il est donc nécessaire de développer des plate-formes innovantes basées sur des standards pour permettre la circulation de ces données entre chercheurs, les organismes d'archivage et éventuellement le public. Pour favoriser la pérennité des contenus audio et de leurs métadonnées associées lors de leur transport, il paraît essentiel d'utiliser – en association avec une base de données standard gérant les processus concurrents – les techniques d'encapsulation modernes proposées par les formats standard de type OGG ou MP3 (voir § 2.3.).

^{1 &}lt;a href="http://svn.parisson.org/telemeta">http://svn.parisson.org/telemeta

2. Le logiciel Telemeta

2.1. Introduction

Telemeta est un logiciel permettant de créer des bases de données audio structurées à partir de fichiers numérisés en y incluant les métadonnées. Il peut être utile pour l'archivage de contenus multimédias provenant par exemple d'anciens disques vinyl ou de bandes magnétiques analogiques et les proposer à la consultation à partir d'un site internet.

Le système Telemeta est basé sur le concept de *collection*. Une *collection* est un emplacement où les sons – ou les albums contenant des sons – seront sauvegardés avec des contrôles de sécurité. Chaque élément audio peut être transcodé automatiquement vers les formats WAV, FLAC, OGG et MP3 en incluant les métadonnées entrées une seul fois.

Le système Telemeta doit enfin proposer une interface en ligne conviviale permettant, la recherche, l'importation et l'exportation des données textuelles et audio.

2.2. Fonctionnalités

Voici quelques autres fonctions importantes offertes par Telemeta:

- Edition des métadonnées pour chaque fichier ou pour chaque album.
- Génération d'un fichier XML contenant toutes les métadonnées pour chaque fichier WAV sauvegardé.
- Export des fichiers originaux vers une partition de type disque dur ou bande magnétique numérique.
- Export des fichiers compressés vers un disque dur dédié à la consultation.
- Création de fichiers de sécurité dit « de récupération » de type PAR2 pour chaque fichier WAV archivé. Ils permettent de récupérer un fichier corrompu.
- Synchronisation des collections archivées vers des serveurs distants (ssh+rsync).
- Marquage audio à partir d'un fichier donné (remixage).

2.3. Formats audio supportés

- WAV (Waveform audio format)
 - o Format des données : PCM
 - o Compression : non
 - o Bits: 16 à 32 bits
 - o Fréquence d'échantillonnage : 44,1 à 192 kHz
 - o Nombre de pistes : 1 à 16
 - o Avantages:
 - Flux audio brut, idéal pour la sauvegarde.
 - Très utilisé par les professionnels.
 - o Inconvénients:
 - Taille des fichiers importantes.
 - Ne peut contenir de métadonnées (impropre à la consultation en ligne).
 - o Référence: http://fr.wikipedia.org/wiki/WAVEform audio format

- FLAC (Free Lossless Audio Codec)
 - o Format des données : FLAC
 - o Compression : oui, sans pertes
 - o Bits: 16 à 24 bits
 - o Fréquence d'échantillonnage : 44,1 à 192 kHz
 - o Nombre de pistes : 1 à 8
 - Avantages:
 - Format libre donc pérenne (Open Source)
 - Flux audio décompressés à la lecture (codec libre).
 - Streamable : idéal pour la consultation et le partage de fichier de bonne qualité.
 - Utilise deux fois moins de place que le WAV.
 - Peut contenir autant de métadonnées que nécessaire.
 - o Inconvénients:
 - Compressé, donc impropre pour la sauvegarde à long terme.
 - o Référence : http://flac.sourceforge.net/

OGG Vorbis

- o Format des données : Vorbis
- o Compression : oui, avec pertes
- o Bits: 16 bits
- o Fréquence d'échantillonnage : 44,1 à 192 kHz
- o Nombre de pistes : 1 à 2
- Avantages:
 - Format libre donc pérenne (Open Source)
 - Flux audio décompressés à la lecture (codec libre).
 - Streamable : idéal pour la consultation et le partage de fichier de moyenne qualité.
 - Peut contenir autant de métadonnées que nécessaire.
 - Optimisé pour les débits variables.
- o Inconvénients:
 - Compressé, donc impropre pour la sauvegarde à long terme.
- o Référence : http://www.vorbis.com

MP3 (Mpeg 1 Layer 3)

- o Format des données : Mpeg
- o Compression : oui, avec pertes
- o Bits: 16 bits
- o Fréquence d'échantillonnage : 44,1 à 192 kHz
- Nombre de pistes : 1 à 2
- Avantages:
 - Format audio très répandu.
 - Flux audio décompressés à la lecture (codec gratuit).
 - Streamable : idéal pour la consultation et le partage de fichier de moyenne qualité.
 - Peut contenir des métadonnées

- o Inconvénients:
 - Nécessite une licence pour l'encodaœ (non libre)
 - Format de métadonnées normalisé (255 champs max)
 - Compressé, donc impropre pour la sauvegarde à long terme.
- o Référence : http://fr.wikipedia.org/wiki/MP3

2.4. Interopérabilité des données.

Aujourd'hui, le format privilégié pour l'échange des données est le XML². Telemeta utilise systématiquement ce format pour la sauvegarde des métadonnées sur disque dur ce qui assure une pérennité des données essentielle. Cependant, le logiciel devra se conformer aux standards d'archivage comme Dublin Core³ et OAI⁴ basés sur XML et utilisés notamment par la BNF. Cette fonctionnalité est en effet nécessaire pour l'accès aux données à travers les différents services des réseaux de bibliothèques.

Le choix de formats audio standards associés à des systèmes de fichiers classiques permet également de s'assurer de la possibilité de récupérer toutes les données depuis d'autres applications.

2.5. Développements nécessaires.

Pour l'instant, Telemeta s'exécute en ligne de commande depuis un serveur de type Linux ou Unix. Il est désormais nécessaire de développer une interface web facilitant l'édition des données (ajout, suppression, édition des champs) et reliée à une base de données standard (type MySQL ou Zope) pour faciliter la gestion des multiples connexions externes.

Cette interface devra pouvoir gérer une hiérarchie d'utilisateurs, chaque niveau hiérarchique ayant des droits particuliers sur la base de données. Nous pouvons différencier quatre niveaux de droit :

- Public : accès en lecture seule, peut rechercher et écouter une partie de la base de données.
- User : accès en lecture seule, peut rechercher et écouter toute la base de données.
- Maintainer : accès en lecture et écriture sur les métadonnées, peut transférer ou mettre à jour des fichiers audio.
- **Administrator**: en addition des permissions du Maintainer, peut modifier la configuration de l'application et plus particulièrement les *super-metadata*⁵.

² http://fr.wikipedia.org/wiki/XML

³ http://dublincore.org/documents/usageguide/

^{4 &}lt;a href="http://www.openarchives.org/">http://www.openarchives.org/

⁵ Les *super-metadata* consistent principalement à décrire des énumérations. En effet, certains champs de données doivent pouvoir prendre uniquement les valeurs contenues dans une liste, comme par exemple la table « Groupe ethnique » de la base de données 4D actuelle du Laboratoire d'Ethnomusicologie (cf. Figure 1). Une table externe liste alors les groupes ethniques valides. Ainsi, seuls les *administrators* devront pouvoir modifier ces listes alors que les *maintainers* pourront uniquement modifier la meta-propriété d'un échantillon à partir des listes définies par les *administrators*.

Par ailleurs, dans l'objectif de voir les fonctionnalités de Telemeta s'adapter à différents métiers, on devra pouvoir :

- développer de manière modulaire, pour favoriser la réutilisation des modules indépendamment des autres.
- Développer en ciblant bien le LEM et le LAM
- Eviter d'une manière générale d'anticiper des demandes hypothétiques
- Lorsqu'une nouvelle demande apparaîtra, développer, re-cibler, supprimer les fonctionnalités inutiles.

Enfin, il sera établit une librairie qui permette l'ajout des fonctionnalités de Telemeta à d'autres applications déjà existantes. De la même manière, il sera intéressant de relier Telemeta à des librairies déjà existantes qui facilite l'indexation semi-automatique et le repérage temporel dans les contenus (Aubio⁶, SemanticHIFI⁷ et WebRadio⁸).

2.6. Une plate-forme de développement libre

Dans le but de partager les opérations d'information et de développement, l'équipe de développeurs a mis en place un Wiki :

http://svn.parisson.org/telemeta/wiki

où il est possible de parcourir les sources du programme :

http://svn.parisson.org/telemeta/browser/trunk

ainsi qu'un dépôt Subversion :

http://svn.parisson.org/svn/telemeta/trunk

Dans le contexte du paragraphe précédent, le système Subversion est crucial, c'est grâce à un tel outil de versionnement que nous pourrons maintenir des branches de développement parallèles et rapatrier des fonctionnalités de l'une à l'autre.

3. Les partenaires

Les partenaires initiaux de ce projet sont le Laboratoire d'Ethnomusicologie (Université Paris X Nanterre, CNRS UMR 7138) et le Laboratoire d'Acoustique Musicale (Université Pierre et Marie Curie, CNRS UMR 7604, Ministère de la Culture et de la Communication).

De nombreuses discussions scientifiques ont déjà été engagées dans le but de définir précisemment les besoins de chacun. Ces besoins Le logiciel Telemeta a été adapté en ce sens et il est désormais nécessaire de créer les tables particulières de la base de données correspondant aux propriétés de chaque metadonnée. La figure 1 montre par exemple la liste des tables de la base du

^{6 &}lt;a href="http://aubio.piem.org/">http://aubio.piem.org/

^{7 &}lt;a href="http://shf.ircam.fr/">http://shf.ircam.fr/

⁸ http://www.ircam.fr/webradio.html

Laboratoire d'Ethnomusicologie qui comporte plusieurs listes prédéfinies à choix multiples. Cette liste doit être prédéfinie mais adaptable par les administrateurs. Il est prévu de migrer les données actuelles (système 4D) vers la nouvelle base de données.

De plus, le projet Telemeta devra coordonner ses développements en parallèle avec des projets ou des communautés déjà existantes comme CASPAR⁹ et Cuidado¹⁰.

4. Les moyens techniques

Pour permettre le stockage massif des données audio-numériques (2500 heures environ pour le LEM et 1000 heures environ pour le LAM), il est nécessaire qu'il s'équipent en matériel informatique de type serveur et supports de stockage. Parisson peut proposer une aide à l'administration de ces serveurs et la programmation de la mise à jour automatique des différentes collections vers des serveurs extérieurs (BNF, CNRS, etc...).

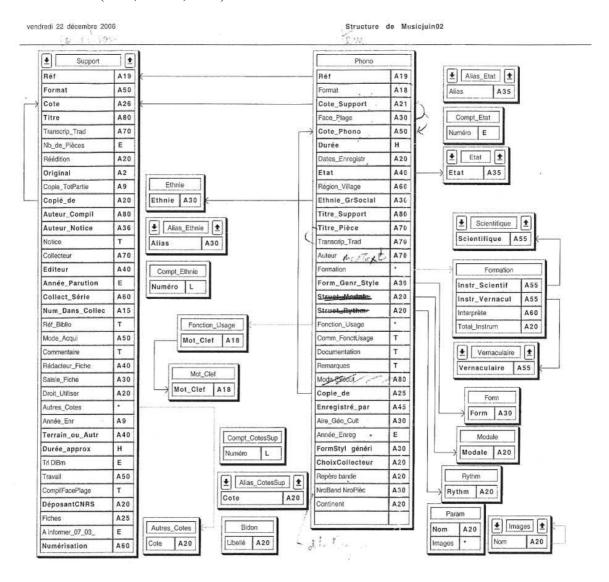


Fig. 1 : Diagramme des tables de données du Laboratoire d'Ethnomusicologie.

⁹ http://www.casparpreserves.eu/

¹⁰ http://www.ircam.fr/34.html?&tx_ircam_pi1%5BshowUid%5D=1&cHash=d2f3380cd4